



APRENDIZAJE NO SUPERVISADO

Clustering del Dry Bean Dataset

Cuatro algoritmos frente a la taxonomía real de 7 especies de frijol:
GMM, Spectral Clustering y Deep Clustering, con K-Means como referencia.

13 611

observaciones

16 → 10

variables de forma

7

clases botánicas

4

metodos comparados

01 El problema y sus reglas de juego



Agrupar sin etiquetas

Cada grano se describe con 16 variables de forma y geometria.

Las 7 clases reales (Seker, Barbunya, Bombay, Cali, Dermason, Horoz, Sira) solo se usan para evaluar el clustering **por fuera**, nunca para entrenar.



Hipotesis del EDA

Bombay es la clase minoritaria y la mas distinta (granos mucho mayores): sera la mas facil de separar. En cambio **Sira y Dermason** tienen formas casi identicas y tenderan a solaparse.

RESTRICCIONES METODOLOGICAS



Sin PCA en ningun paso: ni preprocesamiento ni visualizacion.



Sin DBSCAN para forzar la exploracion de un abanico mas amplio de metodos.

En su lugar, tres tecnicas + un baseline

GMM

Spectral

Deep Cl.

K-Means*

* K-Means solo como referencia; t-SNE con init="random" (evita PCA implicito).

02 Del dato crudo a 10 variables limpias




Un pipeline de tres pasos, sin reduccion lineal de dimension (sin PCA)



03 EDA · Distribuciones de las 16 variables



Histograma y densidad (KDE) de cada variable.



Asimetría a la derecha

Las variables de tamaño (area, perímetro, ejes) tienen colas hacia valores altos.

Múltiples modas

Reflejan la mezcla de especies de tamaños muy distintos, sobre todo Bombay.


Escala dispar

Justifica el escalado obligatorio antes de agrupar.

03 EDA · Boxplots por clase



Distribucion de variables clave separada por especie.



Bombay se despeg Valores de area y perimetro muy por encima del resto: separacion trivial.


Solapamientos Varias especies comparten rangos casi identicos en forma (Sira, Dermason).

Anticipa el resultado Explica por que las metricas externas seran moderadas.

03 EDA · Mapa de calor de correlaciones



Correlacion de Pearson entre las 16 variables.



Colinealidad fuerte

Area, Perimeter, ConvexArea y MajorAxisLength estan casi perfectamente correlacionadas: miden tamaño absoluto.

Motiva la seleccion

De cada par con $|r| > 0.95$ se conserva una sola variable, sin recurrir a PCA.


16 a 10

El resultado es un conjunto de 10 variables menos redundantes e interpretables.

03 EDA · Balance de clases



Cantidad de observaciones por especie.



Desbalance claro

Dermason es la mayoritaria; Bombay, con diferencia, la minoritaria.

Implicancia

Bombay minoritaria pero facil de separar; el desbalance afecta a las metricas externas.

Sin re-muestreo

No se balancea artificialmente: interesa la estructura real de los datos.

04 El arsenal: cuatro formas de agrupar



Todos entrenados sobre la misma submuestra estratificada de 3 000 observaciones (comparacion justa).



REQUERIDO 1

GMM

Mezcla gaussiana con covarianzas elípticas y pertenencia suave (predict_proba).

`k = 3   covariance = full`



REQUERIDO 2

Spectral

Afinidad por vecinos mas cercanos (dispersa) para capturar estructura no convexa.

`k = 7   n_neighbors = 5`



TECNICA AVANZADA

Deep Clustering

Autoencoder
16→32→8→32→16 (no lineal) + K-Means en el espacio latente.

`latent_dim = 8   k = 7`



BASELINE

K-Means


Piso de comparacion simple.
Asume clusters esfericos de igual varianza.

`k = 7`

05 Selección de hiperparametros · K-Means



Metodo del codo (inercia) y silhouette frente a k.



Codo suave La inercia decrece sin un quiebre marcado: la geometría no impone un k obvio.


Elección k = 7 Se fija k = 7 para contrastar directamente contra las 7 clases reales.

Rol de referencia K-Means es el baseline, no cuenta como algoritmo requerido.

05 Selección de hiperparametros · GMM



Grid search sobre componentes y tipo de covarianza (BIC, AIC, silhouette).



BIC sobre-segmenta El BIC solo favorece mas componentes; por eso se combina con silhouette > 0.3.


Selección final covariance = full, n_components = 3 (BIC = -7488, silhouette = 0.317).

Compromiso Equilibra ajuste probabilístico y separación real de los clusters.

05 Selección de hiperparámetros · Spectral



Silhouette frente a k para distintos $n_neighbors$ y asignación.



Mejor en $k = 2$

El máximo silhouette (0.472) corresponde a separar Bombay del resto: trivial.

Se elige $k = 7$

Para una comparación informativa con las 7 especies, asumiendo el costo en silhouette.


Afinidad kNN

$n_neighbors = 5$, $assign_labels = kmeans$; afinidad dispersa por escalabilidad.

05 Deep Clustering · Convergencia del autoencoder



Curva de perdida de entrenamiento y validacion (MSE).



Convergencia estable

Entrenamiento y validacion caen juntos y se estabilizan: sin sobreajuste evidente.

EarlyStopping

Detiene el entrenamiento cuando la validacion deja de mejorar.


Espacio latente

El encoder comprime a 8 dimensiones no lineales sobre las que agrupa K-Means.

05 Deep Clustering · Barrido de k en el latente



Silhouette de K-Means sobre el espacio latente frente a k.



Respaldo de k = 7

El barrido sostiene k = 7 con dimension latente 8 como configuracion final.

No es PCA

El latente es no lineal (activaciones ReLU); captura relaciones que PCA no puede.

Costo mayor

Incluye el entrenamiento del autoencoder: el metodo mas lento del conjunto.

06 La evaluacion: dos varas de medir



Metricas internas (compacidad, sin etiquetas) vs. metricas externas (contra las 7 clases reales).




Tabla completa de metricas

	Sil	DB↓	CH	ARI	NMI
K-Means*	0.28	1.18	1267	0.67	0.71
GMM	0.32	1.44	1202	0.32	0.48
Spectral	0.47	0.68	554	0.03	0.16
Deep	0.20	1.48	936	0.47	0.55


- Mejor metrica interna (Silhouette)
- Mejor metrica externa (ARI / NMI)

Sil = Silhouette · DB = Davies-Bouldin (menor mejor) · CH = Calinski-Harabasz

06 Matrices de confusion alineadas



Alineadas con el algoritmo hungaro (cluster → clase) por metodo.



K-Means Diagonal mas marcada: mejor correspondencia con las especies reales.


Spectral Concentra clases en pocos clusters: alta completitud, baja homogeneidad.

Bombay Se recupera casi perfecta en todos los metodos.

06 Visualizacion con t-SNE



Proyeccion no lineal (init=random) coloreada por clases reales y por cada metodo.



Bombay aislada Forma un grupo separado en todas las proyecciones.


Sira y Dermason Se solapan, coherente con las metricas externas moderadas.

Comparacion visual Permite ver que particion se acerca mas a la estructura real.

06 Visualizacion con Isomap



Segunda tecnica no lineal ($n_neighbors=10$), tampoco PCA, coloreada por clases y por cada metodo.



Distancias geodesicas Preserva la geometria global del manifold recorriendo un grafo de vecinos, no distancias euclidianas directas.

Contraste con t-SNE t-SNE prioriza vecindarios locales; Isomap conserva la estructura global. Dos visiones complementarias.

Refuerza el analisis Dos proyecciones independientes distintas de PCA que se pueden contrastar entre si.

07 El hallazgo: geometria $\neq$ taxonomia



Una buena separacion geometrica no garantiza cercania con la biologia real.

SPECTRAL CLUSTERING

Gana la geometria, pierde la taxonomia

0.47 Silhouette (el mejor)

0.03 ARI (el peor)

Con $k=7$ sobre-segmenta: solo hay una separacion fuerte (Bombay vs. el resto).

K-MEANS (BASELINE)

El mas simple, el mas fiel a la realidad

0.67 ARI (el mejor)

0.28 Silhouette (modesto)

Alta compacidad geometrica no equivale a coincidir con las especies reales.



Deep Clustering queda en el medio (ARI 0.47, NMI 0.55): su espacio latente no lineal supera a GMM y Spectral. La proyeccion **t-SNE** confirma el patron: Bombay se aísla siempre, mientras Sira y Dermason se solapan.

CONCLUSIONES



Que aprendio cada metodo sobre los frijoles

K-Means

El baseline resulto el mas cercano a la taxonomia real (ARI 0.67), pese a asumir clusters esfericos.

GMM

Covarianzas elipticas y pertenencia suave, mas realistas para formas correlacionadas, pero metricas externas bajas.

Spectral

Mejor silhouette de todos gracias a la afinidad por vecinos, pero costoso y desalineado con $k=7$.

Deep Clustering

Mejor compromiso interna/externa que GMM y Spectral, a costa de mayor computo e hiperparametros extra.

LIMITACIONES La submuestra de 3 000 (por el costo de Spectral) reduce el tamano efectivo de entrenamiento; la dimension latente = 8 fue razonada, no optimizada exhaustivamente.

PROXIMOS PASOS Deep Embedded Clustering (DEC/IDEC) con ajuste conjunto de reconstruccion y asignacion, o Spectral sobre el dataset completo via aproximacion de Nystrom.