
APRENDIZAJE NO SUPERVISADO

Informe Técnico del Proyecto Final

José Eduardo Cantero Id

Clustering sobre el Dry Bean Dataset

Contraste de técnicas clásicas y avanzadas: Gaussian Mixture Model, Spectral Clustering y Deep Clustering

Dataset: Dry Bean Dataset, UCI Machine Learning Repository (id 602)
Julio de 2026

1. Introducción

El aprendizaje no supervisado busca descubrir estructura en los datos sin recurrir a etiquetas, lo que lo vuelve especialmente útil cuando se dispone de mediciones abundantes pero no de una clasificación previa fiable. Este proyecto aplica un flujo completo de clustering sobre el Dry Bean Dataset, un conjunto de imágenes de granos de frijol descritos por variables de forma y geometría, con el fin de recuperar de manera no supervisada la estructura que subyace a sus especies botánicas.

El interés del caso reside en que se conocen las clases reales de los granos, lo que permite evaluar la calidad del agrupamiento tanto por criterios internos de compacidad y separación como por su concordancia con la taxonomía verdadera. El trabajo contrasta deliberadamente técnicas clásicas de clustering con una técnica avanzada de aprendizaje profundo, y examina críticamente en qué medida una buena separación geométrica coincide, o no, con la clasificación biológica de las especies.

2. Objetivos

Objetivo general

Aplicar técnicas de aprendizaje no supervisado sobre el Dry Bean Dataset, desarrollando el proceso completo desde el análisis exploratorio hasta la interpretación de los resultados, y contrastando algoritmos clásicos con una técnica avanzada de clustering profundo.

Objetivos específicos

- Caracterizar el conjunto de datos mediante un análisis exploratorio que evalúe calidad, distribuciones, correlaciones, valores atípicos y balance de clases.
- Definir un pipeline de preprocesamiento justificado que reduzca la colinealidad sin recurrir a análisis de componentes principales (PCA).

-
- Implementar y optimizar los hiperparámetros de tres algoritmos de agrupamiento (Gaussian Mixture Model, Spectral Clustering y Deep Clustering), utilizando K-Means únicamente como referencia.
 - Evaluar y comparar los métodos mediante métricas internas y externas, e interpretar críticamente su desempeño.
 - Visualizar la estructura de los datos y de las particiones obtenidas mediante una técnica de proyección distinta de PCA (t-SNE).

3. Dataset

El Dry Bean Dataset reúne **13 611 observaciones** de granos de frijol fotografiados y descritos mediante **16 variables numéricas** derivadas de su forma y geometría (área, perímetro, ejes, excentricidad, solidez y distintos factores de forma, entre otras). Cada grano pertenece a una de **7 clases botánicas** conocidas (Seker, Barbunya, Bombay, Cali, Dermason, Horoz y Sira), que se utilizan únicamente para la evaluación externa de la calidad del clustering y nunca para entrenar los modelos.

Fuente: Koklu, M. y Ozkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174, 105507. El conjunto está disponible públicamente en el UCI Machine Learning Repository (id 602).

4. Análisis Exploratorio de Datos (EDA)

El dataset no presenta valores nulos ni duplicados relevantes. Se analizaron las distribuciones de las 16 variables, su comportamiento por clase, la matriz de correlación y el balance de clases.




Figura 1. Distribuciones (histograma y KDE) de las 16 variables.

La mayoría de las variables geométricas (área, perímetro, ejes) muestran distribuciones asimétricas con colas hacia valores altos, coherente con la presencia de clases de granos de tamaños muy distintos (por ejemplo, Bombay, mucho más grande que el resto).




Figura 2. Boxplots de variables clave por clase.




Figura 3. Mapa de calor de correlaciones entre las 16 variables.

Se detecta alta colinealidad entre las variables de tamaño absoluto (Area, Perimeter, ConvexArea, MajorAxisLength), lo cual se aborda en el preprocesamiento mediante selección de variables por correlación, sin recurrir a PCA.



Figura 4. Balance de clases.

Las clases están desbalanceadas: Bombay es la clase minoritaria y, a la vez, la más distinta geométricamente (granos de mayor tamaño), por lo que se espera que sea la más fácil de separar en

cualquier método de clustering. Se detectan también outliers moderados en variables de forma (Eccentricity, Solidity), que se decide no eliminar agresivamente porque pueden representar variabilidad real entre las 7 especies de frijol y no errores de medición.

Conclusiones previas al clustering

- Existe redundancia clara entre las variables de tamaño absoluto, que conviene reducir antes de agrupar.
- Bombay debería separarse con facilidad; en cambio, especies de forma similar como Sira y Dermason probablemente se solapen.
- El fuerte contraste de escalas entre variables exige un escalado previo obligatorio.

5. Preprocesamiento

El pipeline de preprocesamiento aplica tres pasos, en orden:

- **Imputación** (SimpleImputer, estrategia mediana): el dataset no tiene nulos, pero se incluye por robustez y reproducibilidad del pipeline.
- **Selección de variables** (umbral de correlación de Pearson 0,95): de cada par de variables altamente correlacionadas se conserva la menos redundante, reduciendo la colinealidad detectada en el EDA sin usar PCA y manteniendo variables interpretables.
- **Escalado** (StandardScaler): obligatorio dado que las variables tienen escalas muy distintas (áreas en miles frente a excentricidad en el intervalo [0, 1]); tanto GMM (covarianzas) como Spectral Clustering (afinidades basadas en distancia) son sensibles a la escala.

Tras la selección de variables, las 16 features originales se reducen a **10**: MinorAxisLength, AspectRatio, Eccentricity, EquivDiameter, Extent, Solidity, Roundness, ShapeFactor1, ShapeFactor2 y ShapeFactor4. Las etiquetas de clase se codifican por separado y solo se usan posteriormente para la evaluación externa, nunca para entrenar los modelos de clustering.

6. Metodología

6.1 Restricciones metodológicas

Para este proyecto se definieron dos restricciones deliberadas. No se utiliza PCA en ningún paso (ni en preprocesamiento ni en visualización) ni DBSCAN, con el fin de explorar y contrastar un conjunto más amplio de alternativas. Como algoritmos requeridos se emplean Gaussian Mixture Model (GMM) y Spectral Clustering, ambos clásicos, y Deep Clustering (autoencoder seguido de K-Means en el espacio latente) como técnica avanzada. K-Means puro se usa solo como referencia y no cuenta como uno de los algoritmos exigidos. Para la visualización en dos dimensiones se usa t-SNE con inicialización aleatoria, evitando que utilice PCA internamente como en su configuración por defecto.

6.2 Submuestreo estratificado

Dado el tamaño del dataset (13 611 filas) y el costo computacional de Spectral Clustering, cuya descomposición espectral escala como $O(n^3)$, se define una submuestra estratificada de 3 000

observaciones que se reutiliza de forma consistente para Spectral Clustering, K-Means, GMM y Deep Clustering, de modo que la comparación entre métodos sea justa.

6.3 K-Means (referencia)

Se emplea K-Means como piso de comparación simple. Se fija $k = 7$, igual al número de clases reales, para contrastar directamente contra las etiquetas verdaderas.

6.4 Gaussian Mixture Model

Se realizó una búsqueda de hiperparámetros sobre el número de componentes (2 a 12) y el tipo de covarianza (full, tied, diag, spherical), evaluando BIC, AIC y silhouette. El BIC tiende a favorecer modelos con más componentes o covarianzas más flexibles, lo que puede sobre-segmentar el espacio; por eso la búsqueda se restringe a combinaciones con silhouette superior a 0,3 y, entre ellas, se prioriza el menor BIC. Esto equilibra el ajuste probabilístico del modelo con la calidad de separación entre clusters.

6.5 Spectral Clustering

Se usa una matriz de afinidad basada en vecinos más cercanos (dispersa) en lugar de un núcleo RBF (matriz densa de tamaño $N \times N$) por escalabilidad. Se realizó una búsqueda sobre el número de clusters (2 a 12), el número de vecinos (5, 10, 15 y 20) y el método de asignación de etiquetas (kmeans y discretize), evaluando silhouette.

6.6 Deep Clustering: autoencoder y K-Means en el espacio latente

Se entrena un autoencoder denso simétrico ($16 \rightarrow 32 \rightarrow 8$ latente $\rightarrow 32 \rightarrow 16$, con activaciones ReLU en las capas ocultas y lineal en la salida, pérdida MSE y optimizador Adam) con detención temprana sobre la pérdida de validación. El submodelo encoder extrae un espacio latente de 8 dimensiones sobre el cual se aplica K-Means ($k = 7$). A diferencia de PCA, que es una proyección lineal maximizadora de varianza, el autoencoder emplea activaciones no lineales en encoder y decoder, por lo que puede capturar relaciones no lineales entre las variables de forma y geometría al comprimir el espacio, algo que una proyección lineal no puede representar.

6.7 Protocolo de evaluación

Para los cuatro métodos se calcularon métricas internas (silhouette, Davies-Bouldin y Calinski-Harabasz), que evalúan la compacidad y separación de los clusters sin considerar las etiquetas reales, y métricas externas (ARI, NMI, homogeneidad, completitud y v-measure), que comparan las particiones contra las 7 clases reales de frijol. Para inspeccionar la correspondencia entre clusters y clases se alinean las matrices de confusión mediante el algoritmo húngaro.

6.8 Visualización

La estructura de los datos y de cada partición se visualiza mediante t-SNE, calculado una sola vez sobre la submuestra de 3 000 observaciones con inicialización aleatoria para evitar cualquier uso implícito de PCA.

7. Resultados

7.1 Selección de hiperparámetros

Para K-Means de referencia, el método del codo y el análisis de silhouette respaldan la elección de $k = 7$ como valor de contraste con la taxonomía real.




Figura 5. Método del codo y silhouette para K-Means.

En GMM, la combinación final seleccionada es **covariance_type = full** con **n_components = 3** (BIC = -7488,05, silhouette = 0,317).




Figura 6. Grid search de GMM: BIC, AIC y silhouette.

En Spectral Clustering, la configuración con mayor silhouette (0,472) corresponde a $k = 2$, resultado esperable dado que Bombay se separa de forma muy marcada del resto de las clases. Para una comparación más informativa con las 7 clases reales se selecciona **$k = 7$, $n_neighbors = 5$, assign_labels = kmeans**.




Figura 7. Grid search de Spectral Clustering (silhouette).

En Deep Clustering, el autoencoder converge de forma estable (pérdida de entrenamiento y validación) y el barrido de k sobre el espacio latente respalda k = 7 con dimensión latente 8.




Figura 8. Curva de pérdida (entrenamiento y validación) del autoencoder.




Figura 9. Barrido de k sobre el espacio latente (silhouette).

7.2 Comparación de métodos y tiempos

Método	Hiperparámetros	Tiempo (s)
KMeans (referencia)	k = 7	0,236
GMM	k = 3, covariance = full	0,566
Spectral Clustering	k = 2, n_neighbors = 5, kmeans	0,986
Deep Clustering	latent_dim = 8, k = 7	14,692

El tiempo de cómputo del Deep Clustering incluye el entrenamiento completo del autoencoder, por lo que es sustancialmente mayor que el de los métodos clásicos, aunque todos se entrenan sobre la misma submuestra de 3 000 observaciones.

7.3 Métricas internas y externas

Método	Silh.	DB ↓	CH	ARI	NMI	Homog.	Compl.	V-meas.
KMeans	0,278	1,179	1267,26	0,665	0,708	0,699	0,718	0,708
GMM	0,317	1,436	1201,91	0,323	0,481	0,365	0,704	0,481
Spectral	0,472	0,684	554,48	0,033	0,163	0,089	1,000	0,163
Deep	0,199	1,481	935,56	0,468	0,552	0,537	0,567	0,552

Los valores resaltados en azul marcan el mejor desempeño en métricas externas (K-Means en ARI y NMI); el resultado en terracota indica el mejor silhouette (Spectral Clustering). DB se lee en sentido inverso: cuanto menor, mejor.

7.4 Matrices de confusión alineadas

KMeans (baseline)												
Clase real	0	1	2	3	4	5	6	Clase real	0	1	2	3
0	265	0	10	0	2	2	12	0	177	0	0	1
1	0	114	1	0	0	0	0	1	115	0	0	0
2	290	0	50	0	8	0	11	2	18	0	0	0
3	0	0	3	642	5	26	106	3	1	0	0	0
4	11	0	43	1	358	0	12	4	0	0	0	0
5	1	0	0	7	0	415	24	5	7	0	0	0
6	4	0	6	44	16	4	507	6	7	0	0	0
	0	1	2	3	4	5	6		0	1	2	3
GMM												
Clase real	0	1	2	3	4	5	6	Clase real	0	1	2	3
0	177	0	0	1	113	0	0	0	0	0	0	0
1	115	0	0	0	0	0	0	1	115	0	0	0
2	18	0	0	0	341	0	0	2	0	0	0	0
3	1	0	0	766	15	0	0	3	0	0	0	0
4	0	0	0	2	423	0	0	4	0	0	0	0
5	7	0	0	438	2	0	0	5	0	0	0	0
6	7	0	0	336	238	0	0	6	0	0	0	0
	0	1	2	3	4	5	6		0	1	2	3
Spectral Clustering												
Clase real	0	1	2	3	4	5	6	Clase real	0	1	2	3
0	0	0	0	291	0	0	0	0	0	0	0	0
1	0	115	0	0	0	0	0	1	115	0	0	0
2	0	0	0	359	0	0	0	2	0	0	0	0
3	0	0	0	782	0	0	0	3	0	0	0	0
4	0	0	0	425	0	0	0	4	0	0	0	0
5	0	0	0	447	0	0	0	5	0	0	0	0
6	0	0	0	581	0	0	0	6	0	0	0	0
	0	1	2	3	4	5	6		0	1	2	3
Deep Clustering												
Clase real	0	1	2	3	4	5	6	Clase real	0	1	2	3
0	3	3	205	0	50	0	30	0	3	3	205	0
1	8	106	1	0	0	0	0	1	8	106	1	0
2	12	1	225	0	69	0	52	2	12	1	225	0
3	0	0	3	551	4	65	159	3	0	0	3	551
4	34	0	93	1	287	0	10	4	34	0	93	1
5	0	0	0	77	0	341	29	5	0	0	0	77
6	0	0	26	38	2	1	514	6	0	0	26	38
	0	1	2	3	4	5	6		0	1	2	3

Figura 10. Matrices de confusión alineadas (algoritmo húngaro) por método.

7.5 Visualización con t-SNE




Figura 11. Proyección t-SNE (inicialización aleatoria) coloreada por clases reales y por cada método de clustering.

La proyección permite comparar visualmente la estructura real de las 7 clases contra las particiones producidas por cada método. Bombay forma un grupo claramente separado en todas las proyecciones, mientras que las clases con formas más similares (Sira, Dermason) tienden a solaparse, lo que es consistente con las métricas externas moderadas obtenidas.

8. Discusión

Es esperable que las métricas internas y externas no coincidan perfectamente: el clustering puede encontrar una estructura geométrica válida (buen silhouette) que no calce completamente con la taxonomía botánica, porque especies como Sira y Dermason tienen formas muy similares y se solapan en el espacio de features.

Spectral Clustering logra el mejor silhouette (0,472) pero el peor ARI y NMI (0,033 y 0,163), producto de haber elegido $k = 7$ en una estructura donde en realidad solo existe una separación geométrica fuerte para dos grupos (Bombay frente al resto). En cambio, K-Means obtiene el mejor ARI (0,665) y NMI (0,708) pese a métricas internas más modestas, lo que confirma que una alta compacidad geométrica no garantiza cercanía con la taxonomía real.

Deep Clustering queda en una posición intermedia (ARI 0,468, NMI 0,552), superando claramente a GMM y a Spectral Clustering en métricas externas. Esto sugiere que el espacio latente no lineal del autoencoder captura mejor la estructura de clases que las variables originales usadas por GMM y Spectral, aunque sin alcanzar el desempeño del K-Means de referencia en este conjunto de datos. Bombay es, en todos los métodos, la clase más fácil de recuperar, por ser geoméricamente muy distinta.

9. Conclusiones

- **K-Means (referencia)** ofrece un piso de comparación simple; asume clusters esféricos de igual varianza, lo que limita su capacidad de capturar formas alargadas o irregulares, pero en este dataset resultó el método más cercano a la taxonomía real en términos de ARI y NMI.
- **GMM** permite covarianzas elípticas y asignación suave (probabilidades de pertenencia), lo que es más realista para variables de forma correlacionadas entre sí, aunque en este caso obtuvo métricas externas más bajas que K-Means.
- **Spectral Clustering** puede capturar estructuras no convexas mediante la afinidad basada en vecinos más cercanos y logró el mejor silhouette de todos los métodos, pero es computacionalmente costoso (se recurrió a una submuestra de 3 000 observaciones) y, con $k = 7$, no logró alinearse bien con las 7 clases reales.
- **Deep Clustering** comprime las variables a un espacio latente no lineal de 8 dimensiones y logra un compromiso razonable entre métricas internas y externas, superando a GMM y Spectral en ARI y NMI, a costa de un tiempo de cómputo notablemente mayor y de hiperparámetros adicionales que ajustar.
- **Limitaciones:** el submuestreo estratificado usado por el costo computacional de Spectral Clustering (y aplicado a los demás métodos para comparar de forma justa) reduce el tamaño efectivo de entrenamiento; la dimensión del espacio latente del autoencoder (8) fue fijada de forma razonada pero no optimizada exhaustivamente.
- **Próximos pasos:** explorar variantes de Deep Embedded Clustering con ajuste conjunto de la reconstrucción y la asignación de clusters, o evaluar el costo-beneficio de aplicar Spectral Clustering sobre el dataset completo con técnicas de aproximación espectral (Nyström).

10. Referencias

- Koklu, M. y Ozkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174, 105507.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- Davies, D. L. y Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224–227.
- von Luxburg, U. (2007). A tutorial on spectral clustering. *Statistics and Computing*, 17(4), 395–416.
- van der Maaten, L. y Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
- Hinton, G. E. y Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *Science*, 313(5786), 504–507.
- Xie, J., Girshick, R. y Farhadi, A. (2016). Unsupervised deep embedding for clustering analysis. *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 478–487.